

Grado en
Business Data Analytics

Informe final

Reto 07: Lagun Aro

Curso: 2º 2023-2024

Equipo: Azul Claro

URL del repositorio en GitHub: https://github.com/aitanazas/reto_07_azulclaro.git

Ruta de la carpeta de Google Drive que contiene el proyecto:

[\(Ej. AZUL_CLARO\R7 Proyecto AZUL CLARO\)](#)

Autores:

- Unai Álvarez de Ibarzabal
- Mikel Bernabé Zorroza
- Ane Fernández Quintana
- Guillermo Rubio Ramírez
- Lucía Villuela Cuenca
- Aitana Zas Vara

Índice

Índice	2
1. Introducción	4
2. Identificar la problemática	5
2.1. Sobre el cliente	5
2.2. Sobre la problemática	5
2.3. Objetivos	5
3. Recoger y almacenar los datos	6
3.1. Fuentes de datos utilizadas	6
3.2. Procesamiento de los datos	7
3.2.1. Organización técnica del proyecto	7
3.2.2. Data Discovery & Data Cleaning	7
4. Analizar y modelar los datos	9
4.1. Análisis descriptivos	9
4.2. Modelado de datos	11
4.3. Conclusiones	16
5. Transformar los negocios	
5.1. Estudio financiero	17
5.2. Análisis de sensibilidad	21
5.3. Visualización de los resultados	27
6. Implicaciones legales y éticas	28
Bibliografía	30
Identificar la problemática	30
Glosarios	30
Apéndice I	31
Glosarios	36
Glosario de siglas	36
Glosario de términos	36

Índice de figuras

Figura I - Resumen gráfico Data Discovery & Data Cleaning

Figura II - Boxplot de la distribución de la edad

Figura III - Gráfico de la media de edad de jubilación por sector y distribución de la edad de jubilación

Figura IV - Proporción de rango de sueldos

Figura V - Matriz de correlaciones del segundo conjunto de datos

Figura VI - Análisis del coeficiente de importancia del Dataset 2

Figura VII - Regresión lineal múltiple con datos de entrenamiento y validación

Figura VIII - Evolución de la suma y conteo de las aportaciones mensuales

Figura IX - Histograma con distribución normal (Campana de Gauss)

Figura X - Boxplot de la edad de jubilación

Figura XI - Evolución de la inflación para los próximos 30 años

Índice de tablas

Tabla I - Descripción de variables de la primera hoja del Dataset 1

Tabla II - Descripción de variables de la segunda hoja del Dataset 1

Tabla III - Descripción de variables del Dataset 2

Tabla IV - Ajustes en las variables previas al preprocesamiento.

Tabla V - Resultados de los modelos realizados

Tabla VI - Resumen del cálculo de las rentas

Tabla VII - Pérdidas y ganancias en caso de pagar el 1 de enero de 2024

Tabla VIII - Pérdidas y ganancias en caso de pagar el día de la jubilación

Tabla IX - Pérdidas y ganancias por cada caso de cambio inflación

1. Introducción

El siguiente informe presenta un resumen detallado del proceso de limpieza, transformación, análisis, modelización y visualización de datos llevado a cabo. La solicitud ha sido por parte de la empresa Empaquetados Iberia S.A., que está interesada en mejorar las condiciones de jubilación de sus trabajadores. Para ello, Seguros Lagun Aro realiza un **análisis exhaustivo** de los datos para proponer **soluciones viables y sostenibles**.

En este contexto, se procesan y analizan las dos bases de datos *Dataset1* que contiene características laborales de los empleados y una proyección de la curva de inflación y *Dataset2*, que contiene las edades de jubilación y características de una muestra de trabajadores. Una vez finalizado el procesamiento de los datos, se modeliza la edad de jubilación y se hacen cálculos de primas para el seguro de jubilación.

El **objetivo** primordial de este informe es presentar los resultados del análisis actual y las propuestas económicas para ver si son viables. Finalmente se muestran una serie de conclusiones del análisis teniendo en cuenta las posibilidades y limitaciones de las propuestas de seguro de jubilación.

2. Identificar la problemática

2.1. Sobre el cliente

Lagun Aro es una entidad española de seguros y previsión social, afiliada al Grupo MCC. Ofrece múltiples seguros de coche, hogar, vida, accidentes, ahorro, y para autónomos y empresas. Fundada en 1959 como entidad de previsión social voluntaria, brinda protección a quienes están excluidos del Sistema Público de la Seguridad Social. Su sistema de cobertura mixto combina prestaciones propias con las del Sistema Público de la Seguridad Social, adaptándose a las necesidades actuales.

2.2. Sobre la problemática

La empresa EMPAQUETADOS IBERIA S.A., impulsada por sus beneficios extraordinarios, busca mejorar las condiciones laborales de sus empleados. Para lograrlo, pretende implementar un **plan de complemento de jubilación** que les permita garantizar su seguridad financiera una vez alcancen cierta edad. Sin embargo, se enfrentan a la falta de información precisa sobre la edad de jubilación de su personal. Es por ello que, acude a Seguros Lagun Aro, quienes proponen **tres alternativas** de complemento de jubilación: primas mensuales hasta la edad de jubilación, prima única el 01/01/2024 o prima única al momento de la jubilación. Estas propuestas se han diseñado considerando los escenarios de inflación y proyecciones de inversión proporcionados por un banco de inversión.

2.3. Objetivos

Desarrollar un **modelo predictivo** de la edad de jubilación para los empleados de EMPAQUETADOS IBERIA S.A. utilizando datos de las edades de jubilación y características individuales de una muestra representativa de la población. El propósito es garantizar la viabilidad financiera y el bienestar de los trabajadores en un plazo de tres meses.

3. Recoger y almacenar los datos

3.1. Fuentes de datos utilizadas

Para elaborar la propuesta económica de seguro de jubilación para EMPAQUETADOS IBERIA S.A., se han utilizado tres **conjuntos de datos** proporcionados por el cliente. El primero describe las características laborales de los empleados. El segundo ofrece una proyección de la curva de inflación hasta el año 2150. El tercero contiene datos sobre las edades de jubilación de una muestra de trabajadores y sus características individuales.

Nombre del archivo: Dataset_1.csv / TRABAJADORES Nº registros: 100		
Variable	Significado	Formato
ID	Número de identificación del trabajador	Int64
FECHA NAC	Fecha de nacimiento del trabajador	Datetime64[ns]
SEXO	Sexo del trabajador	Object
NÓMINA BRUTA 01/01/2024	Nómina bruta el 01/01/2024 del trabajador	Float64
FECHA ENTRADA	Fecha de inicio de la relación laboral con la compañía	Datetime64[ns]

Tabla I - Descripción de variables de la primera hoja del Dataset 1

Nombre del archivo: Dataset_1.csv / CURVA_INFLACC Nº registros: 127		
Variable	Significado	Formato
AÑO	Fecha	Int64
TIPO	Evolución Índice de Precios al Consumo (IPC) en incrementos interanuales	Float64

Tabla II - Descripción de variables de la segunda hoja del Dataset 1

Nombre del archivo: Dataset_2.csv Nº registros: 15000		
Variable	Significado	Formato
FechaNacimiento	Fecha de nacimiento del trabajador	Object
UltimoSectorTrabajo	Último registro del sector en el que trabaja	Object
Sexo	Sexo del trabajador	Object
FechaInicioLaboral	Fecha de comienzo de su último contrato laboral	Object
UltimoSueldo	Sueldo anual bruto del último sueldo registrado	Int64
EstaJubilado	Variable binaria. Toma valor "Si" cuando está jubilado	Object
FechaJubilacion	Fecha de jubilación	Object

Tabla III - Descripción de variables del Dataset 2

3.2. Procesamiento de los datos

3.2.1. Organización técnica del proyecto

Primero, se ha establecido un **repositorio** en GitHub y posteriormente, se ha organizado la estructura de directorios utilizando Git en la línea de comandos local. Hecho esto, se ha configurado un **entorno** en Anaconda Prompt y se han instalado las **librerías** necesarias, las cuales se adjuntan en la carpeta de trabajo. Asimismo, se ha elaborado un archivo **README** para documentar el proyecto y proporcionar instrucciones de instalación de las librerías. Después, se ha creado un archivo **.gitignore** para excluir los datos de trabajo del repositorio. Por último, es de comentar que para desarrollar dicho reto, se ha utilizado **Python** como lenguaje de programación.

3.2.2. Data Discovery & Data Cleaning

Una vez establecido un entorno apropiado para el trabajo grupal, se ha realizado la **carga de datos** en VSCode -proporcionadas en archivos csv y xlsx- para su posterior limpieza. Tras esto, se ha llevado a cabo un **análisis genérico** de los datasets con el fin de obtener una visión global del mismo, lo que incluye, descripción de las variables, cambio de formatos, etc. Además, se han realizado estadísticas descriptivas para las variables cuantitativas y se han elaborado tablas de frecuencia para las variables cualitativas.

Una vez completada la carga de datos, se ha llevado a cabo la limpieza del dataset. Inicialmente, se han examinado posibles **duplicados por instancias** debido a la escasez de variables para llevar a cabo un análisis de duplicados por columna. Se ha considerado una instancia duplicada las filas con valores idénticos en todas las variables. Tras esta revisión y como se esperaba, no se han detectado valores duplicados en ningún dataset.

Después, se ha analizado la presencia de **valores ausentes** tanto en variables numéricas como categóricas. Primero, se ha utilizado una herramienta de visualización para representar los missings en una matriz por dataset. Seguido de esto y para verificar dichos valores representados gráficamente, se ha llevado a cabo un recuento de nan por filas y columnas. Únicamente se han detectado valores ausentes en la variable “*FechaJubilacion*” del tercer conjunto de datos. Además, se ha realizado un análisis adicional para entender el origen de estos valores, concluyendo que si la variable “*EstaJubilado*” del mismo dataset codificaba un 'No', era lógico que “*FechaJubilacion*” tuviera un valor nulo.

Finalmente, se han examinado los **valores atípicos** utilizando diagramas de cajas y bigotes -boxplots-. En este contexto, resultaría incoherente establecer límites en los percentiles para identificar los outliers, ya que estos no constituyen errores. En cambio, representan fenómenos genuinos de los usuarios.




Figura I - Resumen gráfico Data Discovery & Data Cleaning

4. Analizar y modelar los datos

4.1. Análisis descriptivos

Con el objetivo de **analizar** las diferentes **variables** que posteriormente se incluirán en el modelo de predicción, se han realizado diferentes gráficos explicativos con el fin de facilitar al cliente la comprensión de los datos. Al tener dos datasets diferentes, se van a intentar explicar las variables de ambos datasets.




Figura II - Boxplot de la distribución de la edad

En primer lugar, como se puede observar en el gráfico número II, se ha tratado de visualizar la **distribución** de la **edad** para ambos datasets, tanto en el que hay que realizar la predicción, como en el de entrenamiento. Se puede apreciar en el boxplot de la derecha, el dataset de entrenamiento tiene un rango de edad bastante más pequeño y, así mismo, estas edades son mayores que las del dataset de trabajadores.




Figura III - Gráfico de la media de edad de jubilación por sector y distribución de la edad de jubilación

Por otro lado, se ha estimado oportuno analizar tanto la variable “UltimoSectorTrabajo” como la de edad de jubilación, correspondientes al dataset de entrenamiento. En este gráfico, a la izquierda se puede observar como no hay apenas **diferencia** en la media de edad de jubilación entre los diferentes sectores de trabajo. Estas medias de edad oscilan en un rango entre 760 y

770 meses, las cuales, como se puede observar en el boxplot de la derecha, se encuentran en torno a la mediana.




Figura IV - Proporción de rango de sueldos

Por último, se ha estimado oportuno analizar el **rango** en el que se encontraban las variables que indican el **último sueldo**. Para ello, se han agrupado los sueldos en cinco grupos diferentes. En este gráfico número IV, se pueden observar las proporciones para cada rango de sueldos. En el gráfico de la izquierda se pueden observar las proporciones para el dataset de entrenamiento, donde se puede apreciar que es el rango de [30000, 35000] el que más valores agrupa. Por otro lado, en lo que respecta al dataset de trabajadores cabe destacar que no existe ningún valor para el rango [50000, 80000], mientras que otra vez es el rango de [30000, 35000] el que más valores agrupa.

4.2. Modelado de datos

Para llevar a cabo el cálculo de las primas, es necesario **predecir** la edad de jubilación de los empleados de Iberia Empaquetados. Para ello, se dispone de un conjunto de datos “*Dataset 2*” para entrenar el modelo. Este dataset contiene información sobre trabajadores que se han jubilado y aquellos que no. Para entrenar adecuadamente el modelo, se requiere la variable objetivo, que en este caso sería la edad a la que se han jubilado. Por lo tanto, es necesario **filtrar** el conjunto de datos para incluir sólo aquellos registros de individuos que sí se han jubilado, permitiendo así que el modelo aprenda de estos casos específicos.

Después de aplicar el filtro, se ha procedido a calcular la **edad de jubilación**. Este cálculo es una operación simple basada en fechas, donde el resultado se ha devuelto en **meses**. Esta conversión se realiza para simplificar el cálculo de las primas de jubilación.

$$Target = Fecha\ Jubilacion - Fecha\ nacimiento$$

Además, se han llevado a cabo cálculos y/o modificaciones en las **variables explicativas** del modelo, dado que este no puede incluir fechas ni variables que no sean numéricas. Tanto la edad actual del cliente en 2024 como la fecha de ingreso a la empresa, se han convertido en meses, ya que se ha decidido trabajar con **unidades de tiempo mensuales**. Asimismo, para representar la variable de sexo en el modelo, se ha transformado en una variable binaria, donde se asigna el valor 1 para masculino -hombre- y 0 para femenino -mujer-.

En cuanto a la variable relacionada con el último sector de trabajo, se ha **eliminado** por dos razones principales. En primer lugar, el dataset que se pretende predecir (*Dataset 1*) no proporciona información específica sobre el sector laboral, lo que impide conocer con precisión en qué sector se encuentran los clientes. En segundo lugar, al calcular la edad promedio de jubilación para cada sector de trabajo previo, se ha observado una escasa variación entre los distintos grupos, como se ha podido observar en los análisis descriptivos, lo que ha llevado a la conclusión de que esta variable carece de una relevancia significativa para el modelo.

Por otro lado, la única variable del segundo conjunto de datos (*Dataset 2*) que no ha requerido modificaciones ha sido la referente a la nómina bruta. Seguidamente, se ofrece una tabla resumen con el procesamiento previo realizado a la modelización:

Nombre del archivo: Dataset_2.csv Nº registros: 15000	
Variable	Modificación
FechaNacimiento	Cambio a unidades mensuales
UltimoSectorTrabajo	Eliminado
Sexo	Cambio a binaria [0-hombre, 1-mujer]
FechaInicioLaboral	Cambio a unidades mensuales
UltimoSueldo	X
EstaJubilado	X
FechaJubilacion	Cambio a formato fecha

Tabla IV - Ajustes en las variables previos al preprocesamiento.

Una vez obtenidas las variables predictoras en sus respectivos formatos, se ha realizado un **análisis de correlaciones e independencia** de las variables. Como se puede observar en la matriz de correlación, ninguna de las variables, excepto la edad, tienen correlación con la variable a predecir. Aún así, se ha decidido analizar todas las variables para ver si existe algún patrón o diferencia que puedan ser diferenciales.




Figura V - Matriz de correlaciones del segundo conjunto de datos

Para ello, se ha decidido realizar diferentes agrupaciones y calcular la media de edad de jubilación por cada agrupación. En primer lugar, se ha agrupado por la variable “Sexo”, donde se han obtenido unos resultados parecidos tanto para hombres como para mujeres, con una media de 761 meses. Por otro lado, se ha realizado una variable nueva llamada “Rango” en la que se ha agrupado la variable “Nómina Bruta” en cuatro intervalos diferentes utilizando la

función `pd.cut()` de la librería `pandas`. Tras realizar estos intervalos, se han agrupado por estos mismos, llegando a la conclusión de que **no existe apenas diferencia** entre intervalos.

Por otra parte, se ha intentado encontrar evidencia que explique la **alta correlación positiva entre la edad y la edad de jubilación**. Tras analizar ambas variables, se ha llegado a la conclusión de que la correlación era tan alta debido a que el conjunto de datos disponible contenía información de **personas recién jubiladas**. Esto se evidencia por la pequeña diferencia media de 6,27 meses entre las edades.

Después de realizar un estudio por variables, se concluye que **ninguna de ellas posee la suficiente representatividad** para ser utilizada en la construcción de un modelo de predicción. Por consiguiente, se especula que los resultados de los modelos de predicción **podrían no ser completamente precisos**. No obstante, se han realizado diversos modelos de predicción con el fin de verificar dichas hipótesis planteadas.

Con el objetivo de evaluar los diferentes modelos, se ha realizado una **división del conjunto de datos** para obtener un set de entrenamiento y otro de validación. Para ello, se ha hecho uso de la función `train_test_split()`, empleando el 80% del dataset para el entrenamiento y el 20% para la validación.

El primer modelo desarrollado ha sido una **regresión lineal múltiple**, utilizando todas las variables excepto la referente a *“UltimoSectorTrabajo”*, por las razones previamente explicadas. Este método estadístico, se ha empleado para analizar la relación entre la variable dependiente -edad de jubilación- y variables independientes -resto de variables del dataset-. Se ha elegido este modelo inicialmente porque, a pesar de su simplicidad, se adecuaba a la perfección para obtener los mejores resultados, ya que este permite estimar cómo varía la edad de jubilación cuando una o más variables del conjunto de datos se modifican.

Previo a la aplicación del modelo, se ha llevado a cabo un **análisis del coeficiente de importancia**. A pesar de haber realizado anteriormente un análisis de correlación, el estudio del coeficiente de importancia ha arrojado resultados en la misma línea, esto es, solo la variable *“Edad”* es relevante para predecir la edad de jubilación, ya que captura la mayor parte de la importancia. No obstante, se ha realizado el modelo con todas ellas.




Figura VI - Análisis del coeficiente de importancia del Dataset 2

Tras realizar el modelo con el conjunto de entrenamiento, se ha llevado a cabo las predicciones con el set de validación para calcular tanto el R^2 como el RMSE. Atendiendo a estos valores, el modelo **parece ser un modelo excelente**, ya que se ha obtenido un R^2 de 0,995 y un RMSE de 3,89. Sin embargo, al realizar las predicciones con el dataset que contienen los trabajadores de EMPAQUETADOS IBERIA S.A., se ha podido comprobar que el modelo de regresión lineal no era el más adecuado, ya que este predecía unos valores entre 271 y 651 meses, algo que carece de sentido.




Figura VII - Regresión lineal múltiple con datos de entrenamiento y validación

Después de **analizar** los **resultados** poco satisfactorios, se ha buscado entender la razón detrás de estos. Se ha encontrado que en el set de datos de entrenamiento, la edad de los trabajadores varía entre 671 y 864 meses. Dado que esta variable es la más relevante en el modelo, como se ha mencionado previamente, las predicciones de la edad de jubilación se limitaban a este rango.

Sin embargo, al considerar que la edad de los trabajadores para los cuales se quiere hacer la predicción tiene un **rango** más amplio, entre 268 y 658 meses según se muestra en la Figura IV,

y al tratarse de una regresión lineal con el método en que el modelo fue entrenado, esta disparidad en los rangos de edad es la principal causa de los resultados poco satisfactorios.

Otro modelo que se ha implementado para resolver esta problemática es **Random Forest Regressor**. La elección de este modelo se basa en su capacidad para manejar tanto variables numéricas como categóricas, su robustez ante valores atípicos y su capacidad de producir resultados precisos y confiables gracias a la combinación de múltiples árboles de decisión.

Una vez entrenados los datos sobre el conjunto de la muestra poblacional, se han **testado**, al igual que en la regresión lineal, en los datos de los empleados de Empaquetados Iberia. Los resultados obtenidos han sido ligeramente mejores que los de la regresión lineal. No obstante, persiste el **mismo problema**, ya que se observa que los resultados predicen una edad de jubilación que oscila entre 665 y 667 meses, lo cual es poco coherente ya que no es común jubilarse a los 55 años.

Después de observar estos resultados, se ha llevado a cabo una **optimización** de los hiperparámetros mediante grid search. A pesar de mejorar estos parámetros, persiste la misma **problemática**: encontrar un modelo o métrica que prediga de manera adecuada la edad de jubilación para los empleados de Empaquetados Iberia. A continuación, se ofrece una tabla resumen con los resultados obtenidos por los diferentes modelos.

MODELO	R ²	RMSE
Regresión lineal múltiple	0.9951992949306122	3.890034765113247
Random Forest Regressor	0.9946318558668079	4.113514700016398
Random Forest Regressor con parámetros optimizados	0.9950538787071765	3.9485109867120864

Tabla V - Resultados de los modelos realizados

4.3. Conclusiones

Como se ha podido observar, las medidas para evaluar los modelos son bastante correctas, pero a la hora de realizar las predicciones no lo hacen correctamente como ya se ha mencionado. Por ello se ha decidido crear un modelo con la **media** de edad de jubilación.

Vistos en esta situación y al ver que ningún modelo de los que se han utilizado funcionaba pese a los buenos resultados, se necesitaba encontrar una medida que pudiera ofrecer resultados confiables y precisos. En el contexto de predecir la edad de jubilación de los trabajadores, la **media** puede ser una medida sólida y efectiva debido a su simplicidad, robustez, eficiencia computacional y capacidad para capturar tendencias centrales en los datos históricos de la población de empleados. La media proporciona una forma intuitiva de interpretar y entender los datos, siendo menos sensible a variaciones pequeñas y ruido en comparación con modelos de machine learning más complejos como los probados. Asimismo, al aprovechar la tendencia central de los datos, la media puede reflejar con mayor precisión la edad promedio de jubilación esperada, especialmente cuando se basa en datos históricos consistentes.

5. Transformar los negocios

5.1. Estudio financiero

Como se viene explicando, el reto trata de estimar la edad de jubilación adecuada de los empleados seleccionados de Empaquetados Iberia, con el objetivo asegurar un complemento de jubilación durante los siguientes 20 años después de su retiro laboral. Es por ello que, Seguros Lagun Aro nos ha encomendado este reto.

Lagun Aro propone **tres escenarios** para Empaquetados Iberia: en el primero, la empresa paga todas las primas el 01 de enero de 2024; en el segundo, las primas se abonarán al momento de la jubilación de cada empleado; y en el tercero, se realizan pagos mensuales de primas hasta la fecha de jubilación. Una vez que se acuerde el caso, Lagun Aro asumirá la responsabilidad de realizar los pagos de las primas a los empleados.

Tras estimar una edad de jubilación de 64 años, se han desarrollado varias funciones para el cálculo de la **fluctuación del capital** en este período. En primer lugar, se han calculado las rentas mensuales pospagables inmediatas que cada trabajador recibirá una vez jubilado. Estas rentas comenzarán a constituirse el primer día del mes siguiente a su jubilación, siendo pospagables y equivaldrán al 1,75% de la nómina mensual bruta del mes anterior a la fecha de jubilación, prorrateada por 12 meses, por cada lustro que el trabajador haya permanecido en la empresa, sin superar el 15%. Además, estas rentas experimentarán un crecimiento del 5% anual que se aplicará en cada mes de enero.

Además, se han tenido en cuenta para el cálculo las previsiones de los mercados financieros. Se proyecta un rendimiento anual esperado del 2% para los ahorros durante los primeros 10 años, y un 1% para los siguientes años. Respecto al tipo de interés para las rentas pospagables, se prevé un 1% anual constante durante los primeros 5 años y medio, y un 2% para el resto del período.

Dicho esto y asumiendo la edad de jubilación que se ha predicho, se han calculado los meses restantes hasta la jubilación para cada cliente desde el 01 de enero de 2024 y se ha obtenido el salario anual de cada empleado ajustado a la inflación, para preservar su poder adquisitivo.

Después de efectuar estos cálculos, se han establecido **dos diferentes rentas**, ambas en **progresión geométrica**, para los próximos 20 años. La primera de ellas, será una renta entera distribuida en períodos inferiores a un año, con fracciones de años que se convierten en pagos mensuales. Por otro lado, el segundo tipo de renta será mensual, constante anualmente, resueltas mediante el ajuste de la fraccionada. Dependiendo del mes de la jubilación de cada empleado, se han determinado un total de cuatro o seis rentas. Los asalariados que se jubilen de enero a mayo, junio, julio a noviembre y diciembre.

Para los asalariados que se jubilen de **enero a mayo** -grupo A-, y de **julio a noviembre** -grupo B-, se han definido un total de **seis rentas** en progresión geométrica. La primera renta para ambos grupos será una renta entera mensual pospagable que abarcará hasta la finalización del año. La distinción entre los grupos radica en la duración de los términos (n) de cada capital que constituye la renta. Para el grupo A, los términos serán superiores a seis, mientras que para el grupo B serán inferiores. La segunda renta, común para ambos grupos, consistirá en una renta mensual pospagable y constante anualmente, adecuada mediante el ajuste de la fraccionada, y con una duración de 48 meses, lo que equivale a cuatro años completos.

La tercera y cuarta rentas seguirán un esquema similar a la primera, debido a la variación en el tipo de interés a los 5 años y 6 meses, que impide un cálculo anual completo. Por lo tanto, la tercera renta abarcará desde el inicio del año hasta el momento del cambio al interés del 1%, y la cuarta será desde ese punto hasta el final del año con un interés del 2%, el cual se mantendrá constante hasta la finalización del cobro del complemento de jubilación. La quinta renta será similar a la segunda, es decir, una renta fraccionada con una duración de 13 años.

Finalmente, la sexta renta será igual que la primera, con la diferencia en los términos entre los grupos. Para los empleados que se jubilan de enero a mayo, los términos serán menores de 6, mientras que para los de julio a noviembre, los términos serán mayores, asegurando un total de 20 años de cobertura.

Por otra parte, para los trabajadores que se jubilan en los meses de **junio** -grupo C- y **diciembre** -grupo D-, se han establecido **cuatro rentas** en progresión geométrica siguiendo la misma lógica que en los grupos anteriores, con etapas definidas.

Los empleados del grupo C recibirán una renta entera durante los primeros 6 meses, hasta el final del año. En cambio, los trabajadores que se jubilan en diciembre no tendrán esta renta, ya que se retiran al final del año y comenzarán a cobrar la prima de jubilación al año siguiente. En su lugar, la primera renta para el grupo D será una renta fraccionada con una duración de 5 años.

La segunda renta, invertirá el patrón anterior para ambos grupos. Los empleados que se jubilan en diciembre recibirán una renta entera hasta el cambio de tipo de interés a los 66 meses, mientras que los del grupo C tendrán una renta fraccionada durante 5 años hasta dicho cambio de interés.

Las tercera y cuarta renta para ambos grupos, serán idénticas. En los 14 años siguientes, se calculará una renta fraccionada. Para cubrir los últimos 6 meses, se ha realizado una renta entera, asegurando así un total de 20 años de renta para cada grupo.

A continuación, se ofrece una tabla resumen con todos los movimientos de salida de capital-primas de jubilación- por parte de Lagun Aro:

	MES DE JUBILACIÓN			
	Grupo A Enero - Mayo	Grupo B Junio	Grupo C Julio-Noviembre	Grupo D Diciembre
Renta 1	Renta entera [n > 6]	Renta entera [n = 6]	Renta entera [n < 6]	Renta fraccionada [n = 60]
Renta 2	Renta fraccionada [n = 48]	Renta fraccionada [n = 60]	Renta fraccionada [n = 60]	Renta entera [n = 6]
Renta 3	Renta entera [n < 66]	Renta fraccionada [n = 168]	Renta entera [n < 66]	Renta fraccionada [n = 168]
Renta 4	Renta entera [n < 72]	Renta entera [n = 6]	Renta entera [n < 72]	Renta entera [n = 6]
Renta 5	Renta fraccionada [n = 156]	X	Renta fraccionada [n = 156]	X
Renta 6	Renta entera [n < 240]	X	Renta entera [n < 240]	X

Tabla VI - Resumen del cálculo de las rentas

Después de realizar todos los cálculos pertinentes, se han determinado los valores de las primas que se desembolsarán al momento de la jubilación de cada empleado. Hecho esto, se han capitalizado las primas de jubilación hasta el 1 de enero de 2024, considerando los tipos de interés correspondientes en cada momento. Por último, para obtener la prima mensual se ha calculado el número de meses restantes hasta la edad de jubilación, teniendo en cuenta el tipo de interés correspondiente.




Figura VIII - Evolución de la suma y conteo de las aportaciones mensuales

5.2. Análisis de sensibilidad

Una vez realizado el estudio financiero, es imprescindible adentrarse en un **análisis** crucial para comprender cómo pequeños cambios en la edad de jubilación de los empleados, la inflación y el rendimiento esperado pueden tener un gran impacto en nuestros **pronósticos financieros**. Los tres elementos mencionados son esenciales en la planificación económica, y variaciones en este aspecto pueden generar consecuencias significativas en las primas a pagar por parte de Lagun Aro y en las rentas mensuales proyectadas.

Mediante este examen se quiere explorar los posibles **escenarios** en los que la edad de jubilación difiere de la estimada, ya sea adelantándose o retrasándose a ella, y la inflación y el rendimiento esperado aumentan o disminuyen. Este análisis de sensibilidad proporcionará una visión detallada de los riesgos financieros asociados con estas variaciones, permitiéndolo así comprender mejor cómo podrían afectar la estabilidad financiera de la empresa. Al examinar diferentes situaciones y evaluar sus efectos en nuestras proyecciones, situaremos nuestros pronósticos en una posición más sólida para tomar decisiones estratégicas informadas.

ESCENARIO EDAD DE JUBILACIÓN

En primer lugar, se han analizado los posibles escenarios en los cuales la **edad de jubilación** se retrase o se adelante a nuestro pronóstico. Para seleccionar las edades de los escenarios, en principio se pensó en seleccionar el valor de la desviación estándar de la edad de jubilación, pero tras analizar detenidamente ese caso se decidió optar por otras opciones. En el siguiente gráfico se puede observar un histograma con distribución normal que muestra la probabilidad de la edad de jubilación. En este caso se puede observar que la edad de jubilación no sigue una distribución normal, por lo que utilizar la desviación estándar sería incorrecto. En una distribución estándar, un 68% de los datos se distribuyen en torno a la primera desviación estándar y un 95% en torno a las 2 desviaciones estándar, pero como la mayoría de datos no se concentra en la media, no es normal, por lo que no tendría sentido aplicarlo.




Figura IX - Histograma con distribución normal (Campana de Gauss)

Para poder optar por edades más correctas a analizar se ha decidido crear un boxplot de la edad de jubilación que muestre la manera en la que están repartidos los valores. Se han seleccionado los valores que están en el percentil 25 y 75 como posibles edades debido a que son valores que describen el conjunto de la muestra de datos correctamente, el valor para estos percentiles es de 48 meses hacia arriba y abajo respecto a la mediana.




Figura X - Boxplot de la edad de jubilación

Una vez seleccionadas las edades con las que se van a calcular los posibles riesgos, se ha procedido a hacer los **cálculos correspondientes** para el primer caso, que corresponde a pagar todas las primas el 1 de enero de 2024. En este caso, la empresa paga a Lagun Aro al principio de la operación. Por ello, se puede deducir que si se jubilan antes Lagun Aro ganaría dinero y en el caso contrario perdería dinero.

PRIMA ÚNICA EL 2024/01/01	
VA_BASE - VA_-48	2.816687e+06
VA_BASE - VA_48	-2.515761e+06

Tabla VII - Pérdidas y ganancias en caso de pagar el 1 de enero de 2024

Como se puede observar en la tabla de resultados, si se jubilase 48 meses antes, Lagun Aro estaría ganando +2.8 Millones de euros a valor de hoy. En cambio, si se jubilase 48 meses después, Lagun Aro estaría perdiendo +2.5 Millones de euros a valor de hoy.

Para el tercer caso, en el cual las primas se abandonarían en el momento de jubilación de cada empleado se han realizado los siguientes cálculos. En primer lugar, las primas mensuales recibidas por los trabajadores desde el 1 de enero de 2024 hasta la edad de jubilación son **inamovibles** debido a que es la realidad, es decir, son las primas que están pagando en la actualidad y ya no se pueden cambiar. Tanto en el caso de reducir como aumentar la edad de jubilación, se ha calculado la renta de cada edad en el momento que se vayan a jubilar sumando las primas mensuales obtenidas por los trabajadores, a esa renta se le ha denominado valor final y se ha actualizado hasta el punto 0.

Una vez obtenida esa renta se ha procedido a recalcular el salario anual con la inflación en los dos casos ya que al cambiar el año de jubilación el salario también cambia. Con los nuevos salarios, se han vuelto a calcular las dos rentas para los próximos 20 años, que como bien se ha mencionado anteriormente, las dos son geométricas. A esta renta se le ha denominado valor actual y se ha actualizado hasta el punto 0. Se han actualizado tanto el valor inicial como el final al punto 0 para poder comparar ahora las pérdidas o ganancias. En la siguiente tabla se muestran los resultados de este caso.

PRIMAS MENSUALES HASTA LA FECHA DE JUBILACIÓN	
VS_con_M_BASE_-48 - VA en_-48	5.121781e+04
VS_con_M_BASE_48 - VA en_48	1.360489e+05

Tabla VIII - Pérdidas y ganancias en caso de pagar el día de la jubilación

Teniendo en cuenta que lo paga con mensualidades de un valor M inamovible, en **ningún caso perdería**, debido a que el cobro mensual de las rentas está pactado y se estaría cobrando desde hoy. Esto ayudaría a Lagun Aro a gestionar de manera más efectiva sus riesgos financieros y evitar pérdidas inesperadas

Finalmente, para el segundo caso, que consta en recibir las primas al final de la jubilación, es indiferente para Lagun Aro, ni perdería ni ganaría nada ya que se **recalcularía** una vez jubilado.

ESCENARIO INFLACIÓN

Por otro lado, se proporcionó un csv con datos de inflación con ciertos valores, que hasta el año 2038 eran diferentes, con cierto decrecimiento, sin embargo, a partir de ese punto el valor pasa a ser un 2% constante anual, a pesar de que el valor es una estimación realista, se ha hecho una búsqueda a fin de conseguir datos históricos sobre la inflación en España anteriores.

Asimismo se han obtenido los datos de la siguiente fuente: "<https://www.ine.es/jaxiT3/Tabla.htm?t=50934&L=0>" , con un total de 20 años, es decir, desde 2003 a 2023.

Con esa realidad, se han obtenido hasta 4 escenarios diferentes:

- CASO 1 : se han sustituido los valores constantes(2%) por la nueva media.
- CASO 2: se han sustituido los valores constantes(2%) por la nueva media, pero aleatorizada, desde el primer cuartil hasta el tercer cuartil.
- CASO 3 : restando 0.005 al valor original (proporcionado por Lagun Aro)(2%)
- CASO 4: sumando 0.005 al valor original (proporcionado por lagun aro)(2%)




Figura XI - Evolución de la inflación para los próximos 30 años

Todos los casos han sido **recalculados** desde el inicio, ya que al cambiar los valores de la inflación los sueldos de los clientes cambian, lo que conlleva a que el valor de M1 cambie, haciendo que todos los valores se desplacen.

Para calcular las pérdidas/ ganancias en este apartado, se ha calculado la diferencia entre el valor actual en 2024/01/01(es el mismo obtenido en el primer escenario con $n = 0$) con los parámetros en la inflación originales y el resto.

Es decir, original - CASO 1, original-CASO 2, etc.

<i>VA original — VA Casos</i>	
CASO 1	- 5.246236e+05
CASO 2	- 4.241529e+05
CASO 3	1.175315e+06
CASO 4	- 1.281127e+06

Tabla IX - Pérdidas y ganancias por cada caso de cambio inflación

Al no haber variación en la variable tiempo, los valores de 2024/01/01, fecha de jubilación y mensualidades de n términos son equivalentes y por lo tanto, con realizar la comparación hoy es suficiente.

En líneas generales, si la inflación obtiene un crecimiento, Lagun Aro perdería dinero, ya que el último salario va a ser mayor, por lo que se le tendría que pagar más dinero a los trabajadores.

ESCENARIO RENDIMIENTO ESPERADO

Para esta tercera variable se ha realizado un procedimiento similar al de la inflación, el rendimiento esperado proporcionado por lagun aro se basa en el tipo de interés de las **letras del tesoro**, por eso mismo, se ha utilizado un excel directamente de "<https://www.tesoro.es/deuda-publica/historico-de-estadisticas/tipo-inter%C3%A9s-medio>", desde el que se ha extraído un decrecimiento del tipo de interés en las letras del tesoro, durante los últimos 21 años, este valor ha tenido un decrecimiento media del 0.19%, así pues, se le han restado un 0.19% al 2% interés anual del rendimiento esperado. **Solo se le aplica al 2%** ya que el otro rendimiento, el 1%, ya es muy pesimista, y quitarle más valor sería exagerado.

Nuevamente, se ha utilizado el VA a 2024 original para el cálculo y se ha recalculado el VA a 2024 desde el inicio para el nuevo rendimiento esperado.

En resumen:

$$VA_{2024} - VA'_{2024}$$

Con esta nueva variación en el rendimiento esperado, Lagun aro perdería un total de

-356241.2177312301 €

Al igual que en la anterior comparación, al no mover variables temporales, con hacer uso de comparación sólo a hoy en día es más que suficiente, ya que ambos otros resultados son equivalentes a el primero.

5.3. Visualización de los resultados

Una vez obtenidos todos los objetivos, se ha procedido a completar el último que trata sobre la creación de una **aplicación Flask**. La creación de dicha aplicación tiene como objetivo agilizar la búsqueda de información del complemento de jubilación de cada trabajador. Además, en caso de ser utilizada por personas sin contexto o conocimiento previo del proyecto, se puede obtener información sobre los objetivos y el contexto del reto en diferentes apartados que se mencionan a continuación.

Para llevar a cabo este proceso se han creado diferentes elementos. En primer lugar, se ha creado un código fuente de Python llamado 'server.py' que contiene las rutas que tiene la aplicación Flask y que plantilla se va a devolver en los diferentes casos de cada ruta. A continuación, se han creado dos carpetas, una llamada 'templates' que contiene las diversas plantillas creadas y otra llamada 'static', que almacena las imágenes que se van a reproducir a lo largo de la aplicación. En la carpeta 'templates' hay un total de 6 plantillas html, durante la creación de la aplicación se hace uso de ellas dependiendo del contenido que se quiere mostrar al usuario.

En la aplicación se pueden observar diferentes **apartados**, cuando se entra por primera vez se, en el apartado 'Ongi etorri' se muestra una página de bienvenida que explica el funcionamiento general. Si se desea conocer tanto el contexto como los objetivos del reto, en las secciones 'Contexto' y 'Objetivos' se pueden observar, con el fin de entender mejor el propósito de la aplicación. En el último apartado llamado 'Login', al introducir el usuario 'reto07' y la contraseña 'azulclaro' accede a la **calculadora de prima de jubilación** creada. En esta sección se muestran las tres opciones de cálculo de primas mencionadas a lo largo del informe que son pagar mensualmente, pagar a la hora de jubilarse o pagar ahora. Una vez seleccionado el método, se muestran ciertos campos para rellenar para finalmente poder devolver la prima a pagar. Dependiendo del método seleccionado la prima será diferente.

6. Implicaciones legales y éticas

Como en todo trabajo o proyecto que se hace uso de datos personales se debe garantizar **privacidad y seguridad** a los clientes. En el caso de Lagun Aro, disponen de diferentes apartados en su página web llamados Aviso legal y Política de privacidad en los cuales mencionan que datos personales son los que pueden utilizar, cuáles son los objetivos de utilizarlos y quienes los utilizan, es decir quien tiene el permiso de acceder a ellos. Siempre que se trata sobre los datos personales es importante proteger la privacidad.

Siguiendo con el hilo de la protección de datos, los datos que se han utilizado sobre los trabajadores de EMPAQUETADOS IBERIA S.A. han sido proporcionados por Lagun Aro. Estos documentos no contienen información personal ya que no aparece en ningún momento el nombre de los trabajadores. Aún así, es cierto que la empresa antes de compartir la información de sus trabajadores ha tenido que explicarles con que objetivo se comparten sus datos y quienes van a tener acceso a ellos. Después, los trabajadores deben dar a la empresa el consentimiento de poder hacer uso de sus datos.

A la hora de crear modelos para estimar la edad de jubilación han surgido algunas limitaciones, como se menciona en la parte de modelado de datos, se ha tenido que entrenar el modelo con un dataset para luego predecir otro distinto. Para evitar posibles sesgos o discriminaciones en los modelos generados, se ha ido comprendiendo de manera matemática el funcionamiento de ellos. Además, se han ido observando los resultados generados por los modelos y las predicciones, pero se ha visto que no eran correctos. Por ello, tras un análisis, se ha optado por crear un modelo con la media.

Se han intentado definir funciones para **adaptarse a posibles cambios**. Para ello, se han supuesto una serie de escenarios, los cuales se tienen en cuenta a la hora de calcular la renta que obtendrá cada trabajador. Estos escenarios ayudan a mitigar riesgos de pérdidas. Se sabe que el valor del dinero actual no será el mismo que el del futuro, por lo que mediante la aplicación de la inflación con el IPC, se han recalculado las rentas que obtendrá cada trabajador para así asegurar que cada uno obtenga su renta correctamente.

Como bien se ha dicho anteriormente, para los **ODS 8 y 12** que tratan sobre Trabajo Decente, Crecimiento Económico, Producción y Consumo Responsable respectivamente, se ha garantizado que la propuesta de jubilación sea financieramente sostenible a largo plazo, sin

comprometer el bienestar económico de los empleados ni la salud financiera de la empresa. Se ha analizado exhaustivamente para evaluar riesgos financieros y para garantizar que el plan sea sostenible en una variedad de escenarios.

Continuando con los ODS, el caso del **ODS 3** que trata sobre Salud y bienestar, el impacto que tendrá el seguro de jubilación en el bienestar y calidad de vida a largo plazo de los trabajadores, será positivo. Los trabajadores obtendrán mensualmente ya sea por la jubilación o por parte de propiedades que dispongan, una renta de otro tipo. Si añaden a esa renta externa, la renta del seguro de jubilación, podrán cubrir las necesidades básicas con mayor holgura. El hecho de obtener mayor liquidez, no hace que se obtenga una mayor calidad de vida o bienestar, pero sí hace que se pueda afrontar la vida con mayor facilidad económica. Viendo la importancia del dinero, el hecho de tener una mayor cantidad del mismo, es un punto positivo.

En el caso de los **ODS 10 y 5**, no se ha hecho una distinción en los trabajadores a la hora de calcular el seguro de jubilación. Siempre que se ha hecho el preprocesamiento de los datos, se ha garantizado que todos los trabajadores estaban dentro del proceso de la misma manera. Una diferencia que había entre los trabajadores por ejemplo era la edad, lo cual era imprescindible para calcular las rentas que obtendría cada trabajador. Otro ejemplo era el sueldo que obtenía cada trabajador, pero no por el hecho de cobrar más o tener una edad existen razones para hacer una manipulación y hacer una distinción entre los trabajadores. Se ha garantizado equidad entre todas las personas trabajadoras en todos los aspectos.

Para justificar los métodos empleados para la modelización de la edad de jubilación y el cálculo de primas o capitales, se han descrito detalladamente las fuentes de los datos utilizados y las técnicas aplicadas para el cálculo de las rentas. Se ha priorizado la transparencia a la hora de calcular las rentas sobre todo.

Bibliografía

Identificar la problemática

Conócenos - Seguros Lagun aro. (s. f.). Seguros Lagun Aro. https://www.seguros lagun aro.com/corporativa/secciones/informacion_corporativa/quienes_somos/quienes_somos.php?idioma=es

Glosarios

Mondragon Corporation. (s. f.). <https://www.mondragon-corporation.com/somos/>

Fernández, Y. (2019, 30 octubre). Qué es GitHub y qué es lo que le ofrece a los desarrolladores. Xataka. <https://www.xataka.com/basics/que-github-que-le-ofrece-a-desarrolladores>

Mijacobs. (2023, 5 octubre). ¿Qué es Git? - Azure DevOps. Microsoft Learn. <https://learn.microsoft.com/es-es/devops/develop/git/what-is-git>

Navas, M. Á. (2023, 23 octubre). Que es CMD ¿Que significa y para qué sirve? Profesional Review. <https://www.profesionalreview.com/2018/06/30/que-es-cmd/>

Rondón, I. (2022, 15 febrero). ¿Qué es Anaconda? -Escuela Internacional de posgrados. International Business School. <https://eiposgrados.com/blog-python/que-es-anaconda/>

<https://anestesiario.org/2020/la-distancia-mas-corta-el-metodo-de-los-minimos-cuadrados/>

Apéndice I

Para poder llevar a cabo los cálculos financieros que necesitamos, se requiere predecir la edad de jubilación de los trabajadores de EMPAQUETADOS IBERIA S.A. con los que vamos a trabajar. Para ello hemos entrenado un modelo de regresión lineal múltiple sobre datos que nos han facilitado sobre otros trabajadores, que incluían como variables independientes el sexo, el último sueldo, la edad actual y la edad de inicio laboral de estos para así poder predecir cual será el momento de jubilación de nuestros trabajadores target. De esta forma y siendo conscientes del periodo trabajado en la empresa, podremos dar respuesta al objetivo del reto. A continuación exponemos en detalle todo lo que hemos precisado para llegar a configurar el modelo que mejor se ajusta a esta situación.

REGRESIÓN

Regresión lineal múltiple

La regresión lineal múltiple es una **técnica estadística** utilizada para comprender y modelar la relación entre una variable dependiente (llamada variable de respuesta o target) y dos o más variables independientes (llamadas variables explicativas). El objetivo principal es desarrollar un modelo que pueda **predecir** el valor de la variable dependiente basándose en los valores de las variables independientes. Este modelo se expresa como una ecuación lineal:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

Donde:

- Y es la variable dependiente.
- $X_1, X_2, \dots, X_n$ son las variables independientes.
- $\beta_0, \beta_1, \beta_2, \dots, \beta_n$ son los coeficientes de regresión que representan la relación entre la variable dependiente y cada una de las variables independientes.
- ϵ es el término de error, que representa la discrepancia entre los valores observados y los valores predichos por el modelo.

Los coeficientes de regresión ($\beta_0, \beta_1, \beta_2, \dots, \beta_n$) se estiman a partir de los datos de la muestra utilizando métodos como los **mínimos cuadrados**, que intentan minimizar la suma de los cuadrados de las diferencias entre las observaciones y las predicciones del modelo.

Este método de los mínimos cuadrados se emplea para calcular la recta de regresión lineal que minimiza los residuos, esto es, las **diferencias entre los valores reales y los estimados** por la recta. Su representación matemática es la siguiente:

$$\hat{B} = (X^t X)^{-1} X^t Y$$

En un modelo de regresión lineal múltiple cada variable independiente está ponderada por un **coeficiente de regresión**, que indica la fuerza y dirección de su efecto sobre la variable dependiente. Además, se añade un término de error para tener en cuenta las disonancias entre los valores observados y los predichos por el modelo.

Tras ajustar un modelo de regresión lineal múltiple, se pueden extraer conclusiones sobre la importancia de cada variable independiente en la predicción de la variable dependiente. Además, se puede evaluar la **calidad del ajuste** del modelo en su totalidad.

Para garantizar la validez y confiabilidad de los resultados del modelo, es esencial verificar ciertas condiciones. Estas incluyen la **linealidad**, que supone una relación directa entre la variable dependiente y las independientes; la **independencia de errores**, donde los residuos no deben correlacionarse entre sí; la **homocedasticidad**, que requiere una varianza constante de errores a lo largo de las variables independientes; y la **normalidad de los residuos**, que indica que estos deben seguir una distribución normal. Cumplir con estas condiciones garantiza que el modelo capture de manera adecuada las relaciones entre las variables y produzca predicciones precisas y confiables.

ENSEMBLE LEARNING

Stacking

Stacking es una técnica de aprendizaje automático que combina múltiples modelos de base para mejorar la **precisión** predictiva. Este enfoque de Ensemble Learning utiliza las predicciones de modelos individuales como características de entrada para un modelo final (meta modelo), que luego realiza la predicción final. Finalmente no se ha hecho uso de Stacking para este caso concreto del reto.

Bagging

Bagging o Bootstrap Aggregating es una técnica de Ensamble Learning utilizada en el **aprendizaje automático** para mejorar la **precisión** y **robustez** de los modelos predictivos. En este enfoque, cada modelo base se entrena en una de estas muestras y las predicciones se promedian para obtener la predicción final. Bagging ayuda a reducir la variación del patrón y evita el sobreajuste, mejorando así la generalización del modelo final.

Random Forest Regressor

Random Forest Regressor es una técnica de aprendizaje automático que se basa en Bagging, una extensión de esta técnica específica para **árboles de decisión**. En Random Forest, se generan **múltiples árboles de decisión** durante el entrenamiento, cada uno entrenado en un subconjunto aleatorio de características y datos de entrenamiento (muestreo bootstrap). Luego, las predicciones de estos árboles se combinan mediante votación o promedio para producir la predicción final. Esto mejora la precisión y generalización del modelo base, haciéndolo más **resistente al sobreajuste** y capaz de manejar conjuntos de datos complejos. La diferencia principal con Bagging es que Random Forest aplica selección aleatoria de características en cada árbol, añadiendo otra capa de aleatoriedad y diversidad al modelo, lo que lo hace más efectivo en la práctica.

Random Forest Regressor con parámetros optimizados

Random Forest Regressor con parámetros optimizados, utiliza la técnica de Bagging para mejorar la precisión y la generalización del modelo base de árbol de decisión. Al igual que Random Forest Regressor sin parámetros optimizados, **genera múltiples árboles** de decisión durante el entrenamiento, **cada uno entrenado en un subconjunto aleatorio** de características y datos de entrenamiento.

Por otro lado, este modelo con parámetros optimizados implica **ajustar los hiperparámetros** del modelo para obtener el **mejor rendimiento posible** en el conjunto de datos dado. Esto se logra mediante técnicas como la **búsqueda de hiperparámetros** (por ejemplo, búsqueda grid o búsqueda aleatoria) o la **optimización bayesiana**, aunque en este caso concreto se ha optado

por grid search. Al ajustar los hiperparámetros, se busca maximizar la precisión del modelo o **minimizar la función de pérdida** específica del problema de regresión.

La optimización de los parámetros asegura un **mejor rendimiento** del modelo, ajustando factores como la profundidad máxima del árbol, el número de árboles en el bosque y el número mínimo de muestras requeridas para dividir un nodo. Esto resulta en un modelo más **preciso y generalizable**, capaz de manejar conjuntos de datos complejos de manera efectiva.

OPTIMIZACIÓN DE HIPERPARÁMETROS

La optimización de hiperparámetros es un procedimiento esencial en el desarrollo de modelos de machine learning, ya que su correcta configuración puede tener un impacto significativo en el rendimiento del modelo. Este proceso implica ajustar las configuraciones que no se aprenden durante el entrenamiento del modelo, conocidas como hiperparámetros, para optimizar su capacidad de generalización y precisión en datos no vistos.

Grid search

Grid Search es una técnica de **búsqueda de hiperparámetros** que se utiliza en aprendizaje automático para encontrar la mejor **combinación de valores** de hiperparámetros para un modelo dado. En lugar de adivinar los valores de los hiperparámetros, el Grid Search especifica una **cuadrícula de posibles valores** para cada hiperparámetro y luego prueba exhaustivamente todas las combinaciones posibles de estos valores. Cada combinación se evalúa mediante **validación cruzada** u otro método de validación y se selecciona la combinación que produce el mejor rendimiento del modelo. Esta técnica es útil para encontrar la **configuración óptima** de un modelo y mejorar su rendimiento predictivo en conjuntos de datos específicos. Sin embargo, **puede ser computacionalmente costosa** si la cuadrícula de búsqueda es grande o si se están probando muchos valores de hiperparámetros.

Media

Dado que ninguno de los modelos previamente empleados ha resultado **eficaz** a pesar de sus buenos resultados iniciales, se necesita encontrar una medida alternativa que pueda brindar **predicciones confiables y precisas**. Finalmente, se ha optado por utilizar la media de la edad

de jubilación como una medida sólida y efectiva para predecir la edad de jubilación de los trabajadores.

La media, también conocida como promedio, es una **medida de tendencia central** que se calcula sumando todos los valores de un conjunto de datos y dividiendo el resultado entre el número total de valores en el conjunto. Matemáticamente, la media se expresa de la siguiente manera:

$$Media = \frac{1}{n} \sum_{i=1}^n x_i$$

Donde:

- n es el número total de observaciones en el conjunto de datos
- x_i son los valores individuales en el conjunto de datos.

Una vez calculada la media de edad de jubilación, podemos emplear este valor como una **estimación** de la edad promedio de **jubilación esperada** para los futuros trabajadores. La ventaja de utilizar la media en este contexto radica en su capacidad para **capturar las tendencias centrales** en los datos históricos de la población de empleados. Además, la media tiende a ser **menos sensible a pequeñas variaciones y ruido** en comparación con modelos de machine learning más complejos.

En resumen, al emplear la media de edad de jubilación como medida para predecir la edad de jubilación de los trabajadores, estamos aprovechando un **enfoque simple pero efectivo** que puede proporcionar resultados confiables y precisos basados en los datos históricos disponibles.

Glosarios

Glosario de siglas

SIGLAS	SIGNIFICADO
MCC	Mondragón Corporación Cooperativa
CMD	Símbolo del sistema de Windows (acrónimo de Command)
IPC	Índice de precios al consumo
R2	Coeficiente de determinación. Mide el ajuste de los datos a la línea de regresión
RMSE	Error cuadrático medio de la raíz. Diferencia entre los valores reales y predichos.

Glosario de términos

Mondragón Corporación Cooperativa (MCC): Grupo empresarial basado en el cooperativismo, fundado en 1956 en Mondragón, España. Se define formalmente como una federación de empresas autónomas, unidas por valores cooperativos y solidarios, que operan en diversos sectores económicos. Su estructura se basa en la democracia interna y la participación de los trabajadores en la gestión y toma de decisiones. (*Mondragon Corporation, s. f.*)

GitHub: GitHub es una plataforma de desarrollo de software basada en la nube que utiliza el sistema de control de versiones Git. Permite a los desarrolladores colaborar en proyectos, llevar un registro de los cambios en el código, realizar seguimiento de problemas (issues), y gestionar el desarrollo de software de manera eficiente. (*Fernández, 2019*)

Git: Sistema de control de versiones distribuido de código abierto que facilita el seguimiento de cambios en archivos de código fuente durante el desarrollo de software. Permite a los usuarios colaborar en proyectos, mantener un historial de cambios, ramificar y fusionar el código de manera eficiente, y revertir a versiones anteriores si es necesario. (Mijacobs, 2023)

Cmd: intérprete de comandos que proporciona una interfaz de línea de comandos para la gestión y ejecución de tareas en el sistema operativo Windows. Es un programa que permite a los usuarios ingresar comandos de texto para realizar diversas operaciones, como administrar archivos y directorios, ejecutar programas, configurar el sistema y realizar otras funciones relacionadas con el sistema operativo. (*Navas, 2023*)

Anaconda Prompt: Interfaz de línea de comandos que viene incluida con la distribución de Anaconda, que es una plataforma de administración de paquetes y entorno de desarrollo para

Python y otros lenguajes de programación. Esta herramienta proporciona un terminal interactivo en el que los usuarios pueden ejecutar comandos para gestionar paquetes, crear entornos virtuales y ejecutar scripts en un entorno basado en Python.*(Rondón, 2022)*

Readme: Archivo de texto que proporciona información básica sobre el proyecto, cómo instalarlo, utilizarlo, y otra documentación relevante para los usuarios.

Visual Studio Code (VSCode): Editor de código fuente que se utiliza para programar en numerosos lenguajes de programación.

Rentas pospagables: Pagos periódicos que se realizan después de un periodo de tiempo especificado.

Rentas mensuales constantes anuales: Pagos mensuales que permanecen iguales de un año a otro.

Optimización bayesiana: Método de optimización que utiliza el teorema de Bayes para encontrar la mejor solución posible.

Fluctuación del capital: Cambios en el valor de un capital o activo financiero a lo largo del tiempo debido a factores como el rendimiento de la inversión y la inflación.

Regresión lineal: Método estadístico utilizado para modelar la relación entre una variable dependiente y una o más variables independientes.

Ajuste de la fraccionada: Proceso de adaptación de una cantidad fraccionada a un periodo de tiempo diferente.

Random Forest Regressor: Un algoritmo de aprendizaje automático basado en árboles de decisión que se utiliza para problemas de regresión.

Interés compuesto: Método de cálculo de interés sobre un principal que también incluye los intereses acumulados en periodos anteriores.

Optimización de hiperparámetros: Proceso de ajuste de los parámetros de un modelo para maximizar su rendimiento.

Tendencia central: Un valor que representa un conjunto de datos de manera central, como la media o la mediana.

Tasa de crecimiento anual: Tasa a la que un valor crece o disminuye anualmente.